

Teoría de Toma de Decisiones

Inferencia bayesiana recursiva

Capítulo 8 de “Bayesian perception: an introduction”, Wei Ji Ma, Kording, Goldreich

Nazareno Faillace

24/07

Inferencia bayesiana + evolución temporal = Inferencia bayesiana recursiva

Idea general: discretizar el tiempo (por ejemplo, en intervalos de 100ms). Utilizar la creencia posterior a tiempo t como la creencia a priori a tiempo $t + 1$. Combino esto con la likelihood del tiempo $t + 1$ para obtener la creencia posterior a tiempo $t + 1$ mediante la regla de Bayes.

$$p(m|x_{i+1}) \propto p(x_{i+1}|m)p(m|x_i)$$

Inferencia bayesiana + evolución temporal = Inferencia bayesiana recursiva


Idea general: discretizar el tiempo (por ejemplo, en intervalos de 100ms). Utilizar la creencia posterior a tiempo t como la creencia a priori a tiempo $t + 1$. Combino esto con la likelihood del tiempo $t + 1$ para obtener la creencia posterior a tiempo $t + 1$ mediante la regla de Bayes.

$$p(m|x_{i+1}) \propto p(x_{i+1}|m)p(m|x_i)$$

Dos casos generales:

- El estado del mundo no cambia con el tiempo → Sistema no dinámico, acumulación de evidencia
- El estado del mundo cambia con el tiempo → Sistema dinámico


Sistema no dinámico - Acumulación de evidencia



El sujeto incorpora información durante una ventana de tiempo. Sea x el estado del mundo y s_i la observación a tiempo i , suponiendo que las observaciones son condicionalmente independientes, tenemos lo siguiente:

$$\begin{aligned} p(x|s_1 \dots s_t) &\propto p(x)p(s_1, \dots, s_t|x) = \\ &= p(x)p(s_t|x) \prod_{i=1}^{N-1} p(s_i|x) \propto \underbrace{p(x|s_1, \dots, s_{t-1})}_{\text{posterior de } t-1} \underbrace{p(s_t|x)}_{\text{likelihood en } t} \end{aligned}$$

Sistema no dinámico - Acumulación de evidencia



El sujeto incorpora información durante una ventana de tiempo. Sea x el estado del mundo y s_i la observación a tiempo i , suponiendo que las observaciones son condicionalmente independientes, tenemos lo siguiente:


$$\begin{aligned} p(x|s_1 \dots s_t) &\propto p(x)p(s_1, \dots, s_t|x) = \\ &= p(x)p(s_t|x) \prod_{i=1}^{N-1} p(s_i|x) \propto \underbrace{p(x|s_1, \dots, s_{t-1})}_{\text{posterior de } t-1} \underbrace{p(s_t|x)}_{\text{likelihood en } t} \end{aligned}$$

Como se trata de una tarea binaria, podemos considerar la variable de decisión dada por:

$$d = \ln \left(\frac{p(x = \leftarrow | s_1, \dots, s_N)}{p(x = \rightarrow | s_1, \dots, s_N)} \right) = \ln \left(\frac{p(x = \leftarrow)}{p(x = \rightarrow)} \right) + \sum_{i=1}^N \ln \left(\frac{p(s_i | x = \leftarrow)}{p(s_i | x = \rightarrow)} \right)$$

Cuando d supera cierta cota superior o cae debajo de cierta cota inferior, el sujeto toma una decisión.

- El estado del mundo cambia a lo largo del tiempo siguiendo cierta dinámica
- Cada estado depende sólo del estado anterior (proceso de Markov)
- El sujeto conoce la dinámica



Sistema dinámico - Caso discreto - Modelo oculto de Markov



Dirección real: I, D

Dirección observada: \leftarrow , \rightarrow

La dinámica del sistema viene dada por:

$$\begin{aligned} p(I_{i+1}|I_i) &= 0,8 & p(I_{i+1}|D_i) &= 0,2 \\ p(D_{i+1}|I_i) &= 0,2 & p(D_{i+1}|D_i) &= 0,8 \end{aligned}$$

Sistema dinámico - Caso discreto - Modelo oculto de Markov



Dirección real: I, D

Dirección observada: \leftarrow, \rightarrow

La dinámica del sistema viene dada por:

$$\begin{aligned} p(I_{i+1}|I_i) &= 0,8 & p(I_{i+1}|D_i) &= 0,2 \\ p(D_{i+1}|I_i) &= 0,2 & p(D_{i+1}|D_i) &= 0,8 \end{aligned}$$

Entonces, utilizando la probabilidad posterior de i y teniendo en cuenta la dinámica, podemos obtener la probabilidad prior de $i + 1$ mediante marginalización:

$$\begin{aligned} p(R_{i+1}) &= p(R_{i+1}|R_i)p(R_i) + p(R_{i+1}|L_i)p(L_i) \\ p(L_{i+1}) &= p(L_{i+1}|L_i)p(L_i) + p(L_{i+1}|R_i)p(R_i) \end{aligned}$$

Sistema dinámico - Caso discreto - Modelo oculto de Markov



Dirección real: I, D

Dirección observada: \leftarrow , \rightarrow

La dinámica del sistema viene dada por:

$$\begin{aligned} p(I_{i+1}|I_i) &= 0,8 & p(I_{i+1}|D_i) &= 0,2 \\ p(D_{i+1}|I_i) &= 0,2 & p(D_{i+1}|D_i) &= 0,8 \end{aligned}$$

Entonces, utilizando la probabilidad posterior de i y teniendo en cuenta la dinámica, podemos obtener la probabilidad prior de $i + 1$ mediante marginalización:

$$\begin{aligned} p(R_{i+1}) &= p(R_{i+1}|R_i)p(R_i) + p(R_{i+1}|L_i)p(L_i) \\ p(L_{i+1}) &= p(L_{i+1}|L_i)p(L_i) + p(L_{i+1}|R_i)p(R_i) \end{aligned}$$

Por otro lado, la función de likelihood viene dada por:

$$\begin{aligned} p(\leftarrow |I) &= 0,8 & p(\rightarrow |I) &= 0,2 \\ p(\leftarrow |D) &= 0,2 & p(\rightarrow |D) &= 0,8 \end{aligned}$$

Sistema dinámico - Caso discreto - Modelo oculto de Markov



Dirección real: I, D

Dirección observada: \leftarrow , \rightarrow

La dinámica del sistema viene dada por:

$$\begin{aligned} p(I_{i+1}|I_i) &= 0,8 & p(I_{i+1}|D_i) &= 0,2 \\ p(D_{i+1}|I_i) &= 0,2 & p(D_{i+1}|D_i) &= 0,8 \end{aligned}$$


Entonces, utilizando la probabilidad posterior de i y teniendo en cuenta la dinámica, podemos obtener la probabilidad prior de $i + 1$ mediante marginalización:

$$\begin{aligned} p(R_{i+1}) &= p(R_{i+1}|R_i)p(R_i) + p(R_{i+1}|L_i)p(L_i) \\ p(L_{i+1}) &= p(L_{i+1}|L_i)p(L_i) + p(L_{i+1}|R_i)p(R_i) \end{aligned}$$

Por otro lado, la función de likelihood viene dada por:


$$\begin{aligned} p(\leftarrow |I) &= 0,8 & p(\rightarrow |I) &= 0,2 \\ p(\leftarrow |D) &= 0,2 & p(\rightarrow |D) &= 0,8 \end{aligned}$$

\rightarrow luego ,aplicamos la regla de Bayes para obtener la probabilidad posterior a tiempo $i + 1$



Se asume que las probabilidades prior y posterior siguen una distribución normal y que la función de likelihood es gaussiana. Por otro lado, se tiene que el sistema evoluciona con la siguiente dinámica:


$$x_{n+1} = Ax_n + \eta \quad A \in (0, 1], \quad \eta \sim N(0, \sigma_\eta^2)$$



Se asume que las probabilidades prior y posterior siguen una distribución normal y que la función de likelihood es gaussiana. Por otro lado, se tiene que el sistema evoluciona con la siguiente dinámica:

$$x_{n+1} = Ax_n + \eta \quad A \in (0, 1], \quad \eta \sim N(0, \sigma_\eta^2)$$

Nuevamente, para obtener la prior de $i + 1$, utilizamos la posterior de i y la dinámica. En este caso, la marginalización da lugar a una convolución de dos gaussianas. Así, si teníamos que la probabilidad posterior a tiempo i es $N(\mu_i, \sigma_i^2)$, entonces la probabilidad prior a tiempo $i + 1$ sigue una distribución $N\left(A\mu_i, \sqrt{A^2\sigma_i^2 + \sigma_\eta^2}\right)$.



Se asume que las probabilidades prior y posterior siguen una distribución normal y que la función de likelihood es gaussiana. Por otro lado, se tiene que el sistema evoluciona con la siguiente dinámica:

$$x_{n+1} = Ax_n + \eta \quad A \in (0, 1], \quad \eta \sim N(0, \sigma_\eta^2)$$

Nuevamente, para obtener la prior de $i + 1$, utilizamos la posterior de i y la dinámica. En este caso, la marginalización da lugar a una convolución de dos gaussianas. Así, si teníamos que la probabilidad posterior a tiempo i es $N(\mu_i, \sigma_i^2)$, entonces la probabilidad prior a tiempo $i + 1$ sigue una distribución $N\left(A\mu_i, \sqrt{A^2\sigma_i^2 + \sigma_\eta^2}\right)$. Luego, podemos aplicar la regla de Bayes para obtener la distribución posterior a tiempo $i + 1$

Al aplicar la regla de Bayes en cada intervalo temporal, tenemos que:

$$\mu_{\text{posterior}} = A\mu_{\text{prior}}(1 - W) + W\mu_{\text{likelihood}} \quad W = \frac{\sigma_{\text{prior}}^2}{\sigma_{\text{prior}}^2 + \sigma_{\text{likelihood}}^2}$$

En el contexto del filtro de Kalman, W es denominada ganancia de Kalman (*Kalman gain*) y sirve para medir si el sujeto le da más peso a la observación o a la estimación a priori.

Sistema dinámico - Caso continuo - Filtro de Kalman

